키워드 뉴스 모니터

Windows 데스크톱 프로그램 · 구현 기술 및 설계 보고서

반복 검색을 줄이고, 기관과 키워드별 주요 뉴스를
한 화면에서 확인하도록 만든 모니터링 프로그램입니다.

분석 기준: 2026년 10월 12일의 프로젝트 소스, 코드 버전 v1.1.0.
화면은 실제 사용 중인 NewsMonitor.exe v1.1.0을 촬영했으며, 기사·설정·상태는 촬영 당시의 값입니다.



그림 1. 실사용 프로그램의 메인 화면 - 실제 수집된 금융권·공공기관 관련 기사

주요 구현	기능의 범위
Python · Tkinter · SQLite	뉴스 수집, 검색 조건, 저장, 카드 화면, 기사 미리보기
RSS · TF-IDF · API 연동	Google/Bing 수집, 본문 비교, 카카오·텔레그램 공유
Windows EXE 배포	Python 없는 PC에서 실행, 버전 확인 및 업데이트

문서 구성

02 구현 언어와 기술 / 03 전체 구조 / 04 설계 과정 / 05 메인 화면
06 기관 등록 / 07 검색 조건 / 08 수집·저장 / 09 요약·미리보기
10-16 중복 뉴스: 라이브러리·특징 추출·계산식·판정·캐시·검증
17 알림·토큰 / 18 화면 설정 / 19 배포 / 20 검증·근거

근거: [S1] 프로젝트 개요 · [S2] 현재 코드 · [S10] 직접 실행 화면

구현 언어와 기술

어떤 기술이 실제로 사용되었는가

주 구현 언어는 Python입니다. 화면, 수집, 검색 규칙, 요약, 알림과 업데이트 로직을 Python 모듈로 나누고 로컬 PC에서 실행합니다. 소스 실행 기준은 Python 3.10 이상이며, 배포 워크플로는 Python 3.12를 사용합니다.

구분	사용 기술	프로그램 안에서의 역할
주 언어	Python	클래스·함수로 UI와 업무 로직을 구현
화면	Tkinter · ttk · Canvas	윈도, 탭, 카드, 미리보기, 둥근 패널·버튼
로컬 저장	SQLite · SQL	기사·검색어 연결·요약·본문 비교·알림 이력
설정 형식	JSON	settings.json, 알림 기사 데이터, 업데이트 메타데이터
뉴스 수집	urllib · XML ElementTree	HTTP 요청과 RSS XML 파싱
본문 추출	HTMLParser · JSON-LD	articleBody 및 기사 본문 영역에서 텍스트 추출
문장 비교	scikit-learn · NumPy	문자 TF-IDF 벡터와 코사인 유사도 계산
동시 작업	threading · queue · futures	수집·본문 처리·알림을 화면 작업과 분리
외부 연동	카카오 API · Telegram Bot API	사용자가 설정한 대상에 새 기사 공유
토큰 보호	ctypes · DPAPI	토큰을 Windows 계정 환경에 묶어 암호화
배포·검증	PyInstaller · unittest · GitHub Actions	단일 EXE 패키징과 자동 테스트·릴리스

의존성 선언: scikit-learn >=1.5,<2 / 빌드 도구 PyInstaller 6.20.0. 실제 EXE의 본문 비교 라이브러리 버전과 사용 범위는 10-16쪽에 상세히 설명합니다. JSON·XML·HTML은 데이터 표현 형식, YAML은 CI 설정, BAT·PowerShell은 실행·업데이트 보조에 사용됩니다.

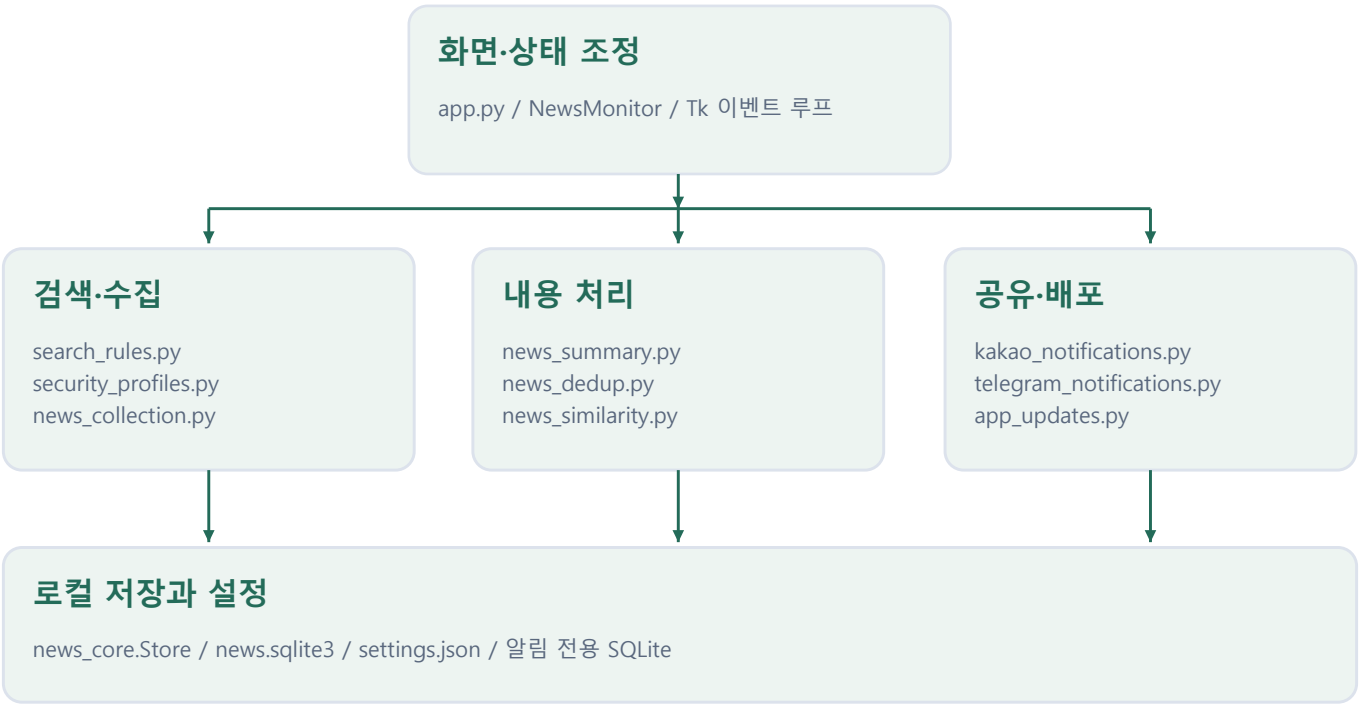
기술 선택의 의미: Tkinter와 SQLite는 화면과 저장을 한 PC 안에서 연결합니다. 뉴스 수집과 발췌 요약에는 별도 AI API 키가 필요 없으며, 알림 기능에는 해당 서비스의 토큰이 필요합니다.

근거: [S1] README · [S2] imports · [S3-S9] 모듈 · requirements 파일

전체 구조와 모듈 설계

화면을 중심으로 서비스 모듈을 연결한 구조

실행 진입점은 app.py의 main()이고, NewsMonitor가 화면 상태와 작업 시작·결과 반영을 조정합니다. 화면과 업무 로직은 파일 단위로 나뉘어 있습니다.



스레드 사이의 책임 분리

작업 위치	주요 책임
GUI 스레드	Tk 위젯 조작, 화면 상태, 기사·요약·비교 결과의 Store 저장
백그라운드 작업	RSS 통신·파싱, 원문 확인·요약, TF-IDF 계산, 알림 대기열 저장·발송
queue.Queue	작업 결과를 이벤트로 전달하고 GUI가 작은 단위로 읽어 반영
revision / 종료 신호	설정 변경 전 작업이나 종료 뒤 늦게 도착한 결과의 반영 방지

구조의 목적은 읽는 화면의 응답성을 유지하는 것입니다. 네트워크 작업은 기다릴 수 있지만, 카드 클릭·페이지 이동·설정 조작은 계속 처리할 수 있도록 구성합니다.

근거: [S2] NewsMonitor · [S3] Store · [S4-S9] 각 서비스

설계 과정과 결정

요구사항에서 구현·안정화·배포까지

아래 단계는 현재 코드와 릴리스 기록을 근거로 재구성한 설계 흐름입니다. 별도의 최초 기획서·개발 일지가 확인되지 않아 실제 작업 순서나 소요 기간으로 단정하지 않습니다.

단계	요구와 설계 결정	확인되는 구현
1. 요구 정의	반복 뉴스 검색, 기관별 사고 확인, 상시 표시	키워드·기관 조건, 최근 기사, 자동 갱신·전체 화면
2. 기반 선택	사용자 PC에서 직접 실행하고 기록 유지	Python + Tkinter + SQLite, EXE 배포
3. 수집 경로	검색 조건을 RSS 후보 수집과 로컬 판정으로 연결	Google 기본, Bing 대체, 공유 쿼리·캐시
4. 정보 품질	관련 없는 보안 기사와 같은 소식의 반복 축소	조건 파서, 사고 근거 필터, 제목·본문 중복 비교
5. 읽기 흐름	화면 갱신 중에도 읽던 기사 위치 유지	대기 결과, 페이지 경계 반영, 미리보기 중 회전 중지
6. 운영 안정화	통신 장애·결과 폭주·재시작에 대응	재시도·쿨다운, 이벤트 분할, 영속 저장, 종료 신호
7. 기능 확장	기관·금융권 목록과 공유·업데이트 관리	분류 편집, API 대기열, 토큰 보호, SHA-256 검증
8. 검증·배포	핵심 동작과 실제 Windows 패키지 확인	unittest, GUI 회귀 테스트, EXE·업데이트 스모크

문제와 구현이 연결되는 예

수집 결과가 한꺼번에 들어오는 경우, 이벤트 큐를 모두 처리하면 화면이 멈출 수 있습니다. process_events()는 한 번에 최대 32개 이벤트와 약 50ms의 처리 예산을 두고, 기사 목록 비교·화면 갱신은 묶음당 한 번 수행합니다. 개별 DB 저장과 마지막 갱신 시간은 이 예산과 별도입니다.

설정 편집은 초안에 적용한 뒤 저장 시 반영합니다. 설정 변경에 따라 revision을 갱신하고, 이전 조건으로 수집한 결과가 뒤늦게 현재 화면에 섞이지 않도록 검사합니다.

근거: [S1] 개요 · [S2-S9] 구현 · releases/v1.1.0.md

메인 화면과 사용자 흐름

뉴스를 읽는 흐름을 유지하는 카드형 화면



그림 2. 실제 뉴스 피드 - 최근 24시간의 수집 기사와 기관별 분류, 수집 진행 상태

화면 영역	사용자가 하는 일	설계상의 의미
상단 버튼	수동 확인, 전체 화면, 공유 설정	자주 쓰는 기능으로 바로 이동
뉴스 피드	전체·키워드·기관 조건 선택	같은 저장소를 조건별로 조회
기사 카드	제목·언론사·발행 시각 확인 후 클릭	미리보기와 원문 확인으로 연결
하단 상태·이동	수집 상태 확인, 이전·다음 페이지	자동 확인 상태와 읽기 위치를 분리

새 결과는 대기 상태로 두고 페이지 전환 또는 「새 결과 보기」에서 적용합니다. 설정·미리보기 창을 여는 동안 자동 페이지 전환은 잠시 멈춥니다. NEW는 발행 시각이 아니라 최초 발견 시각을 기준으로 표시합니다.

근거: [S2] build · render · reload · change_page · [S10] 직접 캡처

기관 등록과 보안 분류

기관·분류·검색어의 세 수준으로 조건 관리



그림 3. 실제 등록 기관 목록과 한국수력원자력의 공격 유형 검색어 설정

기관 이름과 약칭, 분류별 검색어를 데이터로 관리합니다. 정부·공공기관·금융권과 발전사를 등록하고 기관, 분류, 개별 검색어를 켜거나 끌 수 있습니다. 분류 검색어는 최대 200개이며 텍스트 파일 가져오기와 사용자 분류 추가도 제공합니다.

조건의 기본 형태

(기관 이름 OR 약칭) AND (켜진 분류 검색어 중 하나)
여기에 추가 제외어와 확인 범위(제목 / 제목+RSS 설명)를 적용합니다.

기본 보안 분류는 사이버 침해 또는 개인정보·데이터 유출/노출의 근거를 추가 검사합니다. 채용·교육·홍보·소송 중심 기사 등을 제외하고, 현재 조건을 저장된 기사에도 다시 적용합니다. 일반 검색과 다른 사용자 분류에는 이 사고 필터를 적용하지 않습니다.

근거: [S5] 기관 목록·프로필 · [S6] 사고 필터 · group_editor.py · [S10] 화면

검색 조건과 파서 설계

사용자 표현을 검색 요청과 로컬 판정으로 변환

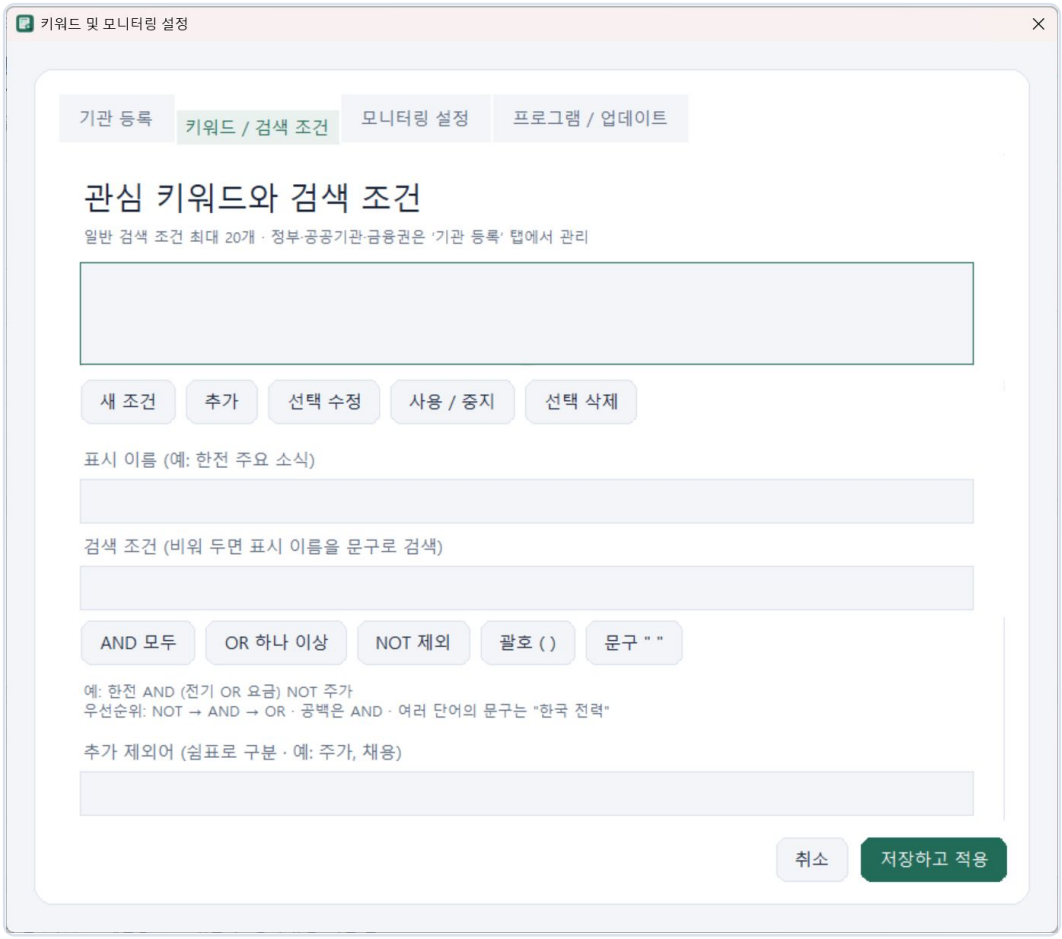


그림 4. 실사용 버전의 일반 검색 조건 입력 화면 - 기관 조건은 별도 탭에서 관리

검색식 처리 흐름

입력 문자열 → 토큰 분석 → 조건 트리 → RSS 검색식 생성 → 후보 기사 수집 → 제목·RSS 설명에서 조건 재평가

표현	판정 방식
AND / OR / NOT	모두 포함 / 하나 이상 포함 / 제외
괄호와 문구	괄호 우선, NOT → AND → OR 순서, 따옴표는 문구
예시	한전 AND (전기 OR 요금) NOT 주가
빈 검색 조건	표시 이름을 문구로 검색하며 기존 키워드 동작 유지

촬영 당시에는 기관 조건으로 운영하여 일반 검색 목록이 비어 있습니다. NOT만으로 된 검색은 거부하며, 기관 약칭별 후보를 공유해 수집한 뒤 기관·분류 전체 조건을 로컬에서 판정합니다.

근거: [S5] Parser · SearchRule · clauses · evaluate · [S10] 화면

수집과 데이터 저장 설계

후보 수집·검사·영속 저장을 연결하는 흐름

RSS는 기사 제목·링크·발행 시각·언론사·설명을 가져오는 기본 경로입니다. 뉴스 검색 RSS에서 후보 기사를 수집한 뒤 조건을 검사하고, 필요할 때 개별 기사 HTML을 확인합니다.

1. 조건 준비
활성 조건 → 공유 쿼리

→

2. RSS 수집
Google 실패 조건 → Bing

→

3. 로컬 검사
시간 범위·조건·사고 근거

테이블	주요 키 / 보관 데이터
articles	url 기본키 / 제목, 언론사, 발행·발견 시각, RSS 설명
matches	(url, keyword) 복합키 / 기사와 검색 조건의 다대다 연결
checks	keyword 기본키 / 조건별 마지막 수집 성공 시각
summaries	url 기본키 / 발췌문, body·rss·unavailable 근거, 확인 시각
article_bodies	url 기본키 / 원문에서 추출한 본문 텍스트 캐시
body_comparisons	기사 URL 쌍 / 본문 해시와 유사도 점수

안정적으로 다시 확인하는 방법

Google 요청은 한 번에 하나씩 최소 5초 간격으로 수행합니다. 수집기 작업자는 최대 4개이고 소켓 대기 제한은 12초입니다. 기본 수집 대기는 600초이며 앱은 쿼리 규모에 맞춰 상한을 늘립니다. ETag·Last-Modified와 304 응답을 이용해 메모리 캐시를 재검증합니다.

429·503은 Retry-After와 지수형 대기 시간을 반영합니다. 실패 시 기존 기사를 유지하고 재시도하며, 늦게 끝난 취소 작업은 반영하지 않습니다. URL 중복은 INSERT OR IGNORE로 방지하고 오래된 기사는 30일 기준으로 정리합니다.

settings.json은 임시 파일 작성 후 교체합니다. 기사 관계에는 외래키와 연쇄 삭제를 적용하며, 요약·본문·비교는 기사별로 연결됩니다. 현재 코드는 추출한 본문을 SQLite에 저장하므로 보관·백업 범위에 이 캐시도 포함해야 합니다.

근거: [S3] Store 스키마 · [S4] NewsCollector · [S2] start_fetch

기사 미리보기와 발췌 요약

원문을 확인한 범위와 요약 근거를 구분



그림 5. 실제 기사 미리보기 - 원문 확인 불가 안내와 기관·검색어 일치 근거

실제 실행에서의 요약 처리

단계	구현 내용
원문 찾기	기사 URL 확인. Google 연결이 불명확하면 동일 제목·언론사·48시간 범위의 Bing 원문 후보 확인
본문 추출	JSON-LD articleBody 또는 article·기사 본문 id/class 영역의 텍스트 선택
핵심 문장 선택	첫 문장 위치와 제목 관련어로 순위를 매겨 최대 3문장·360자 이내로 원래 순서에 맞춰 발췌
근거 표시·저장	본문이면 body, RSS 설명이면 rss, 내용이 부족하면 unavailable로 기록

요약은 실제 기사에서 핵심 문장을 고르는 발췌 방식입니다. 본문 접근 제한·로그인·동적 페이지·지원되지 않는 구조는 RSS 요약으로 대체합니다. RSS 결과와 확인 불가 상태는 24시간 뒤 본문 확인을 재시도합니다.

본문 요청은 한 기사씩, 요청당 10초 대기와 2MB 응답 제한을 둡니다. 기사 본문을 확인하지 못한 상태에서 제목만으로 새로운 내용을 만들지 않습니다.

근거: [S7] ArticleHTML · summarize · ArticleSummarizer · [S10] 화면

중복 뉴스: 라이브러리

1 / 7 - 실제 배포 파일의 버전과 직접·간접 사용 범위

본문 중복 판정의 핵심은 scikit-learn의 TfidfVectorizer입니다. 한국어 본문을 문자 조각의 가중치 벡터로 바꾸고, 두 벡터의 코사인 유사도를 계산합니다. 제목·RSS 규칙과 최종 그룹 구성은 프로젝트가 직접 작성한 Python 코드입니다.

오픈소스 / EXE 버전	실제 역할	사용 구분
scikit-learn 1.9.1	sklearn.feature_extraction.text.TfidfVectorizer로 문자 TF-IDF 특징 추출	비교 함수에서 직접 import
NumPy 2.5.3	np.float32를 벡터의 수치 자료형으로 지정	비교 함수에서 직접 import
SciPy 1.18.1	scikit-learn이 반환하는 희소 행렬의 저장·연산 기반. multiply와 sum으로 내적 계산	희소 행렬을 통한 내부 사용
joblib 1.6.0	scikit-learn 의존성으로 배포에 포함. 이 중복 함수는 Parallel·Memory를 호출하지 않음	간접 의존성
threadpoolctl 3.7.0	scikit-learn의 수치 스레드 관리 의존성. 중복 함수에서 직접 스레드 제한 API를 호출하지 않음	간접 의존성

위 버전은 NewsMonitor.exe의 내장 모듈 버전 상수를 정적으로 확인한 값입니다. news_similarity·news_dedup의 연산 코드와 상수도 현재 소스와 일치함을 확인했습니다. requirements.txt는 scikit-learn >=1.5,<2만 직접 선언하므로 다시 설치·빌드하면 간접 의존성 버전은 달라질 수 있습니다.

어떤 머신러닝 기능을 사용했는가

사용한 기능은 정답 라벨 없이 문서 통계로 특징을 추출하는 TF-IDF입니다. 학습된 분류기가 사건을 예측하는 구조는 아니며, 추출된 특징에 고정 임계값과 사건 분리 규칙을 적용합니다. 사전 학습 언어 모델·문장 임베딩·신경망·생성형 AI API는 이 중복 판정 경로에 사용하지 않습니다.

5개 라이브러리의 주 라이선스는 BSD-3-Clause 계열입니다. NumPy·SciPy 배포물의 포함 구성요소에는 별도 고지가 있을 수 있습니다. PyInstaller는 EXE 포장 도구이며 중복 판정 알고리즘의 라이브러리는 아닙니다.

근거: [S8] 비교 함수 · requirements.txt · [S11] EXE 내장 모듈·라이선스 메타데이터

중복 뉴스: 특징 추출 설정

2 / 7 - 실제 호출 코드와 생략된 기본값까지 확인

현재 코드의 핵심 호출

news_similarity.py / body_score(left, right)
입력은 clean_body()로 정리한 본문 문자열 2개입니다.

```
vectors = TfidfVectorizer(
  analyzer='char', ngram_range=(3, 5),
  sublinear_tf=True, dtype=np.float32
).fit_transform([left, right])
score = float(vectors[0].multiply(vectors[1]).sum())
```

설정	실제 값	의미
analyzer / ngram_range	'char' / (3, 5)	연속된 문자 3개·4개·5개 조각을 모두 특징으로 사용
sublinear_tf	True	반복 횟수 c를 그대로 쓰지 않고 1 + ln(c)로 완화
dtype	np.float32	32비트 부동소수점으로 가중치 계산·저장
norm	기본값: l2	각 문서 벡터 길이를 1로 정규화
use_idf / smooth_idf	기본값: True / True	문서 빈도 가중치와 1을 더하는 평활화 적용
lowercase	기본값: True	벡터화에도 소문자화 적용. 앞 단계에서 이미 casefold 수행
빈도·특징 제한	min_df=1, max_df=1.0, max_features=None, binary=False	특징 수 상한·불용어 목록을 따로 지정하지 않음. 등장 횟수를 이진화하지 않음

fit_transform([left, right])은 비교할 때마다 두 본문만으로 어휘와 IDF를 새로 만듭니다. 전체 기사 말뭉치에 학습한 모델이나 디스크에 저장한 벡터라이저를 재사용하지 않습니다. 캐시는 비교 결과를 재사용하는 장치입니다.

단어 토큰화·한국어 형태소 분석기는 사용하지 않습니다. 예를 들어 "개인정보"의 3그램은 "개인정", "인정보", 4그램은 "개인정보"입니다. 이 예시는 특징 분할 설명용이며 150자 본문 조건을 충족하는 비교 예시는 아닙니다.

공식 근거: scikit-learn TfidfVectorizer API와 매개변수 설명

근거: [S8] body_score · [S11] TfidfVectorizer 기본값 · 공식 API 문서

중복 뉴스: 본문 전처리

3 / 7 - 무엇을 비교하고 어떤 문구를 제거하는가

비교 대상은 360자 발췌 요약이 아니라 원문 HTML에서 추출해 저장한 본문입니다. JSON-LD articleBody 또는 기사 본문 영역에서 얻은 텍스트를 최대 60,000자로 저장하고, 비교용 정리 결과는 최대 30,000자로 제한합니다.

순서	코드의 처리	정확한 범위
1. 구간 분리	줄바꿈 또는 . ! ? 。 뒤 공백에서 분리	문장·줄을 정리하기 위한 정규식 분리이며 형태소 분석이 아님
2. 상용 문구 제거	무단 전재·재배포 금지·저작권·ⓒ·구독·기자 메일·이메일 패턴 검사	패턴이 포함된 구간 전체를 제외하므로 같은 구간의 기사 내용도 빠질 수 있음
3. 반복 제거	dict.fromkeys(lines)	완전히 같은 분리 구간을 최초 순서대로 한 번만 유지
4. 문자열 정규화	Unicode NFKC, casefold, 속보·종합 등 표시와 공백 제거	전각 문자·영문 대소문자·표시 문구 차이 완화. 본문의 모든 구두점을 제거하는 것은 아님
5. 수치·약칭 정리	숫자 사이 쉼표 제거, 만·천 표현 변환, 일부 "여" 제거, 발전사 약칭 통합	"2만 4천여 명" → "24000명", "한전" → "한국전력"
6. 길이 검사	정리된 본문을 30,000자로 자른 뒤 최소 150자 검사	두 본문 모두 150자 이상인 기사 쌍만 본문 비교 대상으로 선택

길이 제한과 대체 경로

MIN_BODY=150의 단위는 정규화한 Python 문자열의 문자 수입니다. 원문 글자 수·단어 수·토큰 수와 다르며, 공백과 상용 문구를 제거한 결과로 검사합니다. 긴 기사의 30,000자 이후 내용은 본문 유사도에 들어가지 않습니다.

본문이 없거나 너무 짧으면 compare_bodies()는 해당 쌍의 본문 점수를 생성하지 않습니다. 유효한 저장 점수가 없는 경우 제목·RSS 규칙으로 판단합니다. body_score() 자체도 짧은 입력에는 0을 반환하지만, 정상 작업 경로에서는 먼저 비교 후보에서 제외합니다.

근거: [S7] ArticleHTML.text · [S8] clean_body · normalize · MIN_BODY

중복 뉴스: 계산식과 의미

4 / 7 - 두 본문에서 TF-IDF와 코사인 점수가 만들어지는 과정

문자 조각 g가 본문 d에서 등장한 횟수를 c(g,d), 비교 문서 수를 N, g가 등장하는 문서 수를 df(g)라고 하면 현재 설정은 다음과 같이 계산합니다. 이 구현에서는 N=2입니다.

단계	현재 설정의 계산식과 해석
TF: 반복 빈도	c > 0일 때 tf(g,d) = 1 + ln(c(g,d)) 등장하지 않은 특징의 가중치는 0. 반복 문구가 점수를 독점하는 효과를 완화
IDF: 문서 빈도	idf(g) = ln((1 + N) / (1 + df(g))) + 1 두 문서에 모두 있으면 1, 한 문서에만 있으면 1 + ln(3/2), 약 1.405465
가중치 벡터	w(g,d) = tf(g,d) × idf(g) 각 3·4·5그램의 가중치를 희소 벡터에 저장
L2 정규화	v(g,d) = w(g,d) / sqrt(Σ w(g,d)²) 본문 길이에 따라 가중치 총량이 커지는 영향을 줄임
코사인 유사도	s(A,B) = Σ v(g,A) × v(g,B) 두 벡터가 이미 단위 길이이므로 내적이 코사인 유사도와 같음

실제 연산과 점수 해석

코드는 sklearn.metrics의 cosine_similarity()를 호출하지 않습니다. 반환된 희소 행렬의 첫째·둘째 행을 multiply()로 원소별 곱셈하고 sum()으로 합산합니다. norm의 기본값 l2가 적용되므로 이 연산이 코사인 점수입니다.

가중치가 음수가 아니므로 점수는 수학적으로 0~1입니다. float32 반올림에 따라 미세한 수치 차이는 생길 수 있습니다. 예를 들어 동일 본문도 이번 실행에서는 0.99999994가 나왔습니다.

0.82 이상이면 같은 소식으로 볼 수 있는 본문 조건을 충족합니다. 0.82는 코드에 고정된 임계값이며 "82% 정확도", "같은 사건일 확률 82%"를 뜻하지 않습니다. 비교 쌍마다 IDF가 달라지고 수치·기관 규칙도 함께 작동하므로 의미적 동등성을 보장하는 점수가 아닙니다.

공식 근거: TF-IDF 가중치와 L2 정규화
공식 근거: 정규화된 벡터의 내적과 코사인 유사도

근거: [S8] body_score · [S11] 공식 TF-IDF·코사인 정의 및 기본값

중복 뉴스: 판정의 우선순위

5 / 7 - 본문 결과가 없을 때 적용하는 제목·RSS의 정확한 조건

1. 현재 본문 지문과 일치하는 점수가 있으면: 그 점수 ≥ 0.82만 사용합니다.
2. 유효한 본문 점수가 없으면: 제목·RSS의 same_story() 규칙을 사용합니다.
본문 점수가 낮거나 사건 분리 규칙으로 0이 저장되면, 제목이 비슷하더라도 RSS 판정으로 되돌아가 합치지 않습니다.

제목·RSS 규칙의 준비

제목과 RSS 설명을 정규화하고 비단어 문자를 제거한 뒤, 연속 문자 2개 조각의 집합을 만듭니다. 동일 조각의 반복 횟수는 세지 않습니다. Dice(A,B) = 2 × |A∩B| / (|A|+|B|)이며, 빈 집합이면 0입니다.

t는 전체 제목 Dice, c는 제목 앞부분 Dice입니다. 앞부분은 말줄임표 "…" 또는 점 2개 이상 이전의 구간이며, 12자 미만이면 전체 제목을 사용합니다. d는 RSS 설명 Dice로, 양쪽 설명의 고유 2그램 수가 모두 30개 이상일 때만 계산하고 아니면 0입니다.

다음 중 하나를 만족하면 RSS 단계에서 일치

조건	정확한 임계값
전체 제목 또는 앞부분 유사	t ≥ 0.82 또는 c ≥ 0.78
같은 발전사 + 공통 제목 수치	양쪽 발전사 집합이 같고 비어 있지 않으며 제목 숫자 교집합이 있을 때 c ≥ 0.64
같은 발전사 + 설명 보조	같은 비어 있지 않은 발전사 집합, d ≥ 0.28, 그리고 c ≥ 0.62 또는 (제목 숫자 교집합 존재 및 t ≥ 0.48)
제목과 설명의 복합 근거	max(t,c) ≥ 0.48 그리고 d ≥ 0.68

유사도 계산보다 먼저 검사하는 조건

발행 시각 차이가 48시간을 넘거나, 양쪽의 발전사 집합이 다르거나, 양쪽 제목 숫자가 있지만 공통 숫자가 없거나, 부정 표현 여부가 다르면 제외합니다. 발전사가 양쪽 모두 검출되지 않으면 원제목의 첫 구간(공백·쉼표·콜론·말줄임표 전)을 정규화한 값도 같아야 합니다.

위 사전 검사를 통과하고 정규화한 전체 제목이 정확히 같으면 짧은 제목도 일치합니다. 같지 않으면서 앞부분이 한쪽이라도 12자 미만이면 제외하고, 그 외에는 위 Dice 기준을 적용합니다. RSS 설명은 원문 본문이나 발췌 요약과 별개의 필드입니다.

근거: [S8] deduplicate.matches · same_story · _features · _dice · [S3] 현재 해시 검증

중복 뉴스: 사건과 그룹 분리

6 / 7 - 높은 본문 점수만으로 합치지 않는 조건과 묶음 방식

두 본문이 충분히 길어도 eligible()의 사전 검사에 실패하면 TF-IDF 연산을 건너뛰고 0을 저장합니다. 따라서 DB의 0에는 실제 낮은 유사도뿐 아니라 규칙에 따른 제외도 포함될 수 있습니다.

본문 비교 전 검사	제외 조건
시간·기관	발행 시각 차이 > 48시간. 또는 양쪽에 발전사 집합이 있고 서로 다름
제목의 수치·부정	양쪽 제목 숫자 집합이 비어 있지 않으나 교집합 없음. 또는 "노출/유출/해킹/발생" 뒤 6자 이내 "없/않/아니" 검출 여부가 서로 다름
제목의 사건 종류	유출·노출·해킹·랜섬웨어 / 임금·연봉·급여·임단협 / 보호대책·보안강화·보호강화 / 발전소건설·발전소착공의 4종 패턴. 양쪽 종류 집합이 있고 교집합이 없으면 제외
본문의 단위별 수치	숫자 뒤 년·월·일·명·건·원·%·곳·개사를 찾음. 같은 단위의 값이 양쪽에 있는데 공통 값이 하나도 없으면 제외

기관 검사는 등록 기관 전체가 아니라 COMPANIES의 한국전력·한수원·5개 발전사·한전기술·KPS·KDN·원자력연료, 총 11개 발전그룹사와 약칭에 한정됩니다. 사건 종류·부정·수치 검사는 정규식 규칙이며 범용 개체명 인식이나 문맥 추론 모델이 아닙니다. 같은 단위의 일부 값만 겹쳐도 수치 검사를 통과할 수 있습니다.

그룹의 모든 구성원과 비교하는 직접 구현

A-B = 0.95
A와 B는 묶을 수 있음

B-C = 0.95
B와 C도 서로 비슷함

A-C = 0.20
C는 A-B 묶음에 못 들어감

최신 발행 순서로 기사를 순회하면서 기존 묶음의 모든 기사와 matches()가 참인 첫 묶음에 추가합니다. 위 예시는 {A,B}와 {C}의 두 묶음이 됩니다. K-means·DBSCAN·연결 요소 알고리즘을 호출하는 구조가 아니며, 순서에 따라 결과가 달라질 수 있는 탐욕적 구성입니다.

각 URL의 원본 행은 DB에 유지합니다. 최신 발행 기사가 대표가 되고, 검색 태그·언론사 목록은 중복 없이 합치며 발견 시각은 가장 이른 값을 사용합니다. 키워드·기간·현재 검색 규칙을 먼저 적용하므로 대표 기사는 현재 조회 범위 안에서 정해집니다.

근거: [S8] eligible · compare_bodies · deduplicate · security_profiles.COMPANIES

중복 뉴스: 캐시와 검증

7 / 7 - 실행 경로, 재현 수치, 성능과 확인된 한계

위치	구현과 역할
작업 실행	Tk 화면 스레드와 분리한 news-grouping 스레드 1개에서 쌍별 비교. 종료 신호 확인, queue로 결과 전달 후 화면 측에서 저장·갱신
메모리 캐시	functools.lru_cache: clean_body 최대 4,096건, body_score 최대 8,192쌍, 제목·설명 특징 최대 8,192건. joblib 캐시 사용 안 함
영속 비교 캐시	SQLite body_comparisons에 URL 쌍·양쪽 본문 지문·점수 저장. 지문 = SHA-256("tfidf-char-v1" + 정리된 본문), 변경 검출용이며 의미 유사도는 아님. 양성·음성 결과 모두 캐시
본문 변경·재시작	현재 지문과 일치하는 점수만 사용하고 변경 시 재계산. 삭제된 기사에는 늦은 결과를 저장하지 않음. 벡터·학습 모델·그룹 ID는 저장하지 않으며 그룹은 조회 때 구성

이번 분석에서 실제 함수로 재현한 예시

입력 변화	코사인 값	실제 판정 점수
동일 본문 (정리 후 182자)	1.000000	약 1.000000 / 본문 조건 충족
후속 문장 추가 (182자 ↔ 204자)	0.901947	0.901947 / 본문 조건 충족
24000명 → 3000명 (182자 ↔ 181자)	0.951411	0.000000 / 수치 충돌로 제외

예시는 tests/test_news_similarity.py의 한국전력 개인정보 유출 본문을 사용한 계산 검증용 데이터입니다. 실사용 화면의 뉴스에 대한 측정값은 아닙니다. 마지막 행의 코사인 값은 설명을 위해 별도로 직접 계산했으며 정상 경로에서는 사전 검사로 그 계산을 건너뜁니다.

이번 보강 중 중복 관련 테스트 11개를 실행: 1.802초 / OK.
동일 본문·기관/수치/부정 분리·짧은 본문·48시간·캐시 변경·취소·연쇄 합병 방지·원본 보존·재시작을 검증했습니다. 정답 라벨 말뭉치로 Precision·Recall·F1을 평가한 기록은 확인되지 않았습니다.

48시간 안의 후보가 n개이면 쌍은 최대 n(n-1)/2개이며, 미캐시 쌍마다 벡터를 새로 만듭니다. 시간·길이·사건 검사와 캐시로 계산을 줄이지만 대량 수집 시 비용이 커질 수 있습니다. 크게 바뀌 쓴 문장, 본문 접근 실패, 정규식에 없는 기관·사건 표현에는 중복 누락이나 오묶음이 남을 수 있습니다.

근거: [S2-S3] 작업자·Store · [S8] 캐시 · [S11] EXE 검사·실행 결과 · tests/

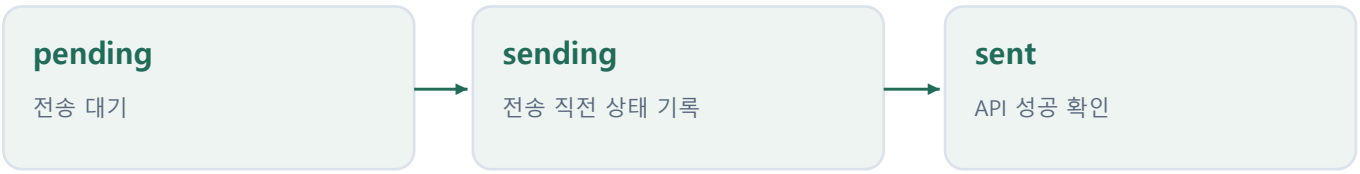
알림 연동과 토큰 보호

영속 대기열로 발송 상태를 관리

카카오와 텔레그램은 수집된 기사 목록을 공유하지만 계정·대상 설정과 전송 기록은 각각의 SQLite 파일로 관리합니다. 설정된 대상의 연결 이후 발견한 새 기사만 대기열에 넣습니다.

기능	카카오	텔레그램
공유 대상	등록 사용자별 나에게 보내기	단체방 또는 채널 한 곳
연결 정보	접근 토큰, 선택적 갱신 설정	봇 토큰, 선택한 방
중복 방지	사용자·URL별 전송 이력	(chat_id, url) 복합키
저장소	kakao.sqlite3	telegram.sqlite3
운영 처리	사용자 ON/OFF, 갱신·재시도	최소 4초 간격, 429 대기, 오류 시 공유 중지

텔레그램 전송 상태 흐름



명확한 오류는 failed로 기록합니다. 시간 초과·전송 중 종료·응답 이상은 unknown으로 남기고, 결과가 불명확한 기사를 자동 재전송하지 않습니다. Telegram API 성공 여부와 사용자의 휴대폰 알림 소리·팝업은 별개입니다.

토큰의 저장과 화면 분리

ctypes로 Windows CryptProtectData / CryptUnprotectData를 호출해 토큰을 DPAPI로 보호합니다. 암호화된 값만 로컬 DB에 보관하며 기존 Windows 계정·PC 환경에서 복호화합니다. 토큰 입력은 마스킹하고 전송 예외에 원시 토큰을 기록하지 않도록 처리합니다.

> 알림 대기열 저장과 API 호출은 작업 스레드에서 실행합니다. 네트워크나 알림 DB의 잠금이 Tk 이벤트 루프를 오래 잡지 않도록 분리한 설계입니다. 실제 발송은 등록 대상의 수신 상태와 공유 설정에 따라 동작합니다.

근거: [S9] 카카오·텔레그램 모듈 · [S2] 알림 작업자

화면 설정과 사용성 설계

동일한 디자인 토큰과 읽기 상태 관리



그림 6. 실제 모니터링 설정 - 검색 간격 15분, 조회 기간 24시간, 시스템 테마

항목	촬영 당시 설정 / 허용 범위
검색·조회	수집 완료 후 15분(10~60분) / 최근 24시간(1~168시간)
페이지	20초(5~300초) / 페이지당 5개(3~8개), 화면에 맞춰 감소
NEW·테마	발견 후 10분(1~60분) / 라이트·다크·시스템
공통 UI 규칙	모서리 16px, 내부 여백 20px, 섹션 간격 12px

카드 폭·높이에 따라 제목을 줄이고 설명을 생략할 수 있으며, 전체 제목은 미리보기에서 확인합니다. Tab으로 카드에 이동하고 Enter·Space로 열 수 있습니다. F11은 전체 화면, Esc는 해제, 좌우 방향키는 페이지 이동입니다.

촬영 당시 자동 넘김은 OFF입니다. 시스템 테마는 Windows 앱 색 모드를 따르며, 설정·미리보기 창을 닫은 후 반영해 읽는 중 상태 변화가 끼어들지 않도록 합니다.

근거: [S2] 레이아웃·테마 · ui_theme.py · smooth_list.py · [S10] 화면

EXE 배포와 자동 업데이트

검증한 파일을 다음 실행에서 교체



그림 7. 실사용 업데이트 화면 - 현재·최신 버전 v1.1.0과 마지막 확인 시각

배포 파이프라인

버전 태그 / 수동 워크플로 → unittest → PyInstaller EXE 빌드 → 패키징 GUI·본문 비교 검증 → 업데이트 교체·재시작 검증 → EXE·SHA-256·릴리스 노트 게시

업데이트 적용 흐름

실제 EXE는 시작 5초 후와 6시간마다 GitHub 최신 정식 릴리스를 확인합니다. 현재보다 높은 버전의 EXE를 내려받아 SHA-256과 Windows 실행 파일 형식을 검사하고 대기 메타데이터를 저장합니다.

다음 실행에서 별도의 숨김 PowerShell 도우미가 기존 프로세스 종료를 기다린 후 파일을 교체합니다. 기존 EXE를 .previous로 보관하고, 교체·재실행 명령 실패 시 복원합니다. 기존 실행 인수와 사용자 data 폴더는 이어서 사용합니다.

> PyInstaller는 Tk 런타임·아이콘·본문 비교 의존성을 EXE에 묶습니다. data·토큰·로그는 배포 파일에 넣지 않습니다. SHA-256은 파일 무결성 확인이며 EXE 코드 서명은 포함되어 있지 않습니다.

소스 실행: python app.py / 전체 화면: --fullscreen 옵션
배포 실행: NewsMonitor.exe / 임의 저장 위치: --data-dir 옵션

근거: [S2] main · [S9] app_updates · NewsMonitor.spec · CI 워크플로 · [S10] 화면

검증 범위와 확인 근거

코드·직접 실행·테스트 기록을 구분

이번 문서 작성 중 실행: 174개 테스트 / 86.118초 / OK.
직접 촬영: 실제 사용 중인 EXE의 메인·미리보기·기관·검색·모니터링·업데이트 화면 6종.

검증이 다루는 주요 문제

RSS 파싱·날짜·검색 조건·DB 저장, Google/Bing 대체·캐시·취소, 사고 관련성, 요약 대체, 본문 변경·중복 그룹, UI 응답·페이지 경계, 알림 중복·실패·토큰, 업데이트 검증·버전 처리에 대한 테스트가 구성되어 있습니다.

현재 구현의 실무적 한계

RSS 검색 색인 범위 때문에 모든 기사의 수집을 보장하지 않습니다. 제목·RSS 설명에 근거가 부족하면 사고 필터가 기사를 제외할 수 있습니다. 원문 접근 제한과 동적 HTML은 요약·본문 비교를 제한합니다. 프로그램이 종료되어 있거나 PC가 절전 중이면 수집하지 않습니다.

자료 목록 - 본문 근거 번호

번호	확인 자료와 역할
S1	README.md, version.py, releases/v1.1.0.md / 제품 개요·버전·기능 기록
S2	app.py, ui_theme.py, smooth_list.py / 실행·스레드·화면·설정
S3	news_core.py / Article, Store, 파싱, SQLite 스키마
S4	news_collection.py / RSS 수집·캐시·쿨다운·대체·취소
S5-S6	search_rules.py, security_profiles.py, institution_catalog.py, group_editor.py, incident_filter.py / 조건·기관·관련성
S7-S8	news_summary.py, news_dedup.py, news_similarity.py / 본문 추출·요약·중복 비교
S9	알림 모듈, app_updates.py, NewsMonitor.spec, requirements 파일, scripts/, .github/workflows/ / 공유·보호·검증·배포
S10	2026.10.12 실사용 NewsMonitor.exe v1.1.0 캡처 / 실제 기사·등록 기관·저장 설정·버전 확인 상태
S11	EXE 내장 버전·중복 모듈과 소스의 코드 일치, 라이브러리 METADATA, TF-IDF 기본값·계산 예시·중복 테스트 실행 / 10-16쪽. 알고리즘 정의는 각 쪽의 scikit-learn 공식 문서 링크 참조

기술 분석은 확인한 로컬 소스에 근거하며, 프로그램 이미지는 실제 사용 중인 EXE에서 촬영했습니다. 기사·수집 상태·설정 값은 촬영 시점에 따라 달라질 수 있습니다. 기술 선택의 이유는 구현 구조에서 도출한 설명입니다.

근거: [S1-S11] 아래 자료 목록 · tests/ · 프로젝트 검증 로그